

De la classification des chiffres manuscrits à la détection de cancers du sein

N. Mekideche A. Lauener M. Ouadihi M. Pierson

Juin 2026

Introduction

Ce rapport analyse trois problèmes de classification d’images de complexité croissante : MNIST (chiffres manuscrits, 10 classes, 60 000 images), CIFAR-10 (objets naturels, 10 classes, 50 000 images) et CBIS-DDSM (mammographies médicales, binaire, 1 696 images).

1 MNIST : classification de chiffres manuscrits

Données et protocole

Chaque image est aplatie en $\vec{x} \in \mathbb{R}^{784}$, normalisée dans $[0, 1]$. Trois familles de modèles sont comparées (100 itérations, $lr = 0,1$, batch= 256, entropie croisée).

Évolution des modèles selon la profondeur et la taille des couches

Modèle linéaire. Le score de la classe k est $o_k = A\vec{x} + b$ avec $A \in \mathbb{R}^{10 \times 784}$ (7 850 paramètres). Il apprend un gabarit moyen par classe sans exploiter d’interaction entre pixels — ce qui suffit sur MNIST grâce au fond blanc uniforme et aux chiffres centrés (92,49% de précision). **MLP à une couche cachée (H=1)** : L’ajout de p_1 neurones avec activation ReLU :

$$\vec{z} = \text{ReLU}(A\vec{x} + b) \in \mathbb{R}^{p_1}, \quad \vec{o} = A\vec{x} + b \in \mathbb{R}^{10}$$

permet de construire des représentations intermédiaires non linéaires. Comme le montre le tableau 1, le gain par rapport au modèle linéaire est de +4,1 points à $p_1 = 128$. La progression se poursuit régulièrement jusqu’à $p_1 = 512$ (96,18%) : avec ReLU, le gradient reste actif ($\text{ReLU}'(z) = 1$ pour $z > 0$) et la convergence n’est pas entravée par la saturation. **MLP à deux couches cachées (H=2)** : L’architecture en entonnoir $784 \rightarrow p_1 \rightarrow p_2 \rightarrow 10$ force une compression progressive : la première couche détecte des caractéristiques simples (bords, courbes), la seconde les combine en motifs plus complexes. Le gain de H=1 [128] à H=2 [128, 64] est de +1,27 points (95,73% → 97,00%) — la deuxième couche combine les caractéristiques intermédiaires en motifs plus abstraits. Le rendement marginal s’effondre ensuite : de H=2 [128, 64] à H=2 [512, 256], on ne gagne que +0,35 point supplémentaire, signe que la capacité dépasse la complexité intrinsèque du dataset.

TABLE 1 – MNIST — comparaison des modèles (100 iter., $lr = 0,1$, batch= 256, seed= 42).

Modèle	Params	Err. Train	Err. Test	Acc. Test
MLP H=1 [64] relu	50 890	4,16%	4,64%	95,36%
MLP H=1 [128] relu	101 770	3,88%	4,27%	95,73%
MLP H=1 [256] relu	203 530	3,50%	3,93%	96,07%
MLP H=1 [512] relu	407 050	3,37%	3,82%	96,18%
MLP H=2 [128, 64] relu	109 386	2,03%	3,00%	97,00%
MLP H=2 [256, 128] relu	235 146	1,89%	2,94%	97,06%
MLP H=2 [512, 256] relu	535 818	1,58%	2,65%	97,35%

Analyse des erreurs

278 exemples sont mal classés simultanément par les trois modèles principaux. Ces erreurs se concentrent sur les paires ambiguës (3, 8), (4, 9), (5, 6), confirmées par la projection ACP (figure 5 en annexe) : les classes 0 et 1 sont linéairement séparables dans $\mathbb{R}^{784}$, tandis que 3/8 et 4/9 se chevauchent. Ce plancher d’erreur est intrinsèque aux

données, pas une limitation du modèle. Pourquoi MNIST reste simple : Fond blanc uniforme, chiffres centrés, faible variabilité intra-classe : le modèle linéaire apprend des gabarits efficaces par classe. Ces propriétés disparaissent sur CIFAR-10.

2 CIFAR-10 : classification d'objets naturels

Limite structurelle du MLP

CIFAR-10 présente des fonds complexes, des translations et des occlusions. Un MLP traite chaque pixel indépendamment : un avion en haut à gauche et le même avion en bas à droite activent des poids totalement différents. Cette absence d'invariance de translation plafonne irrémédiablement les performances.

TABLE 2 – CIFAR-10 — progression des modèles (50 iter., $lr = 0,1$ pour MLP ; $lr = 0.01$ pour CNN).

Modèle	Données	Acc. Test	Err. Test
Linéaire	Gris (1 024)	24,45%	75,55%
MLP [128] sigmoid	Gris (1 024)	33,74%	66,26%
MLP [256] sigmoid	Gris (1 024)	33,07%	66,93%
Linéaire	Couleur (3 072)	40,03%	59,97%
MLP [128] sigmoid	Couleur (3 072)	42,85%	57,15%
MLP [256] relu	Couleur (3 072)	49,94%	50,06%
MLP [256, 128] relu	Couleur (3 072)	47,69%	52,31%
CNN 4 blocs	Couleur	80,83%	19,17%

Observation sur la couleur. Passer de gris (1 024 features) à couleur (3 072 features) ne gagne que +9 points avec sigmoid/128 neurones : la couleur brute non structurée nourrit faiblement un MLP de petite capacité. Avec relu et une architecture plus large ([256]), la couleur permet d'atteindre 49,94% : l'activation non-saturante exploite mieux l'information chromatique que sigmoid dont le gradient s'atténue hors de $[-2, 2]$.

Opération de convolution et filtres K1–K6

La convolution répond au problème d'invariance spatiale :

$$(X * K)[i, j] = \sum_{u=0}^{k-1} \sum_{v=0}^{k-1} X[i+u, j+v] \cdot K[u, v]$$

Un seul filtre 3×3 (9 paramètres) détecte la même structure locale partout dans l'image — contre $32 \times 32 \times 9 = 9\,216$ poids distincts pour un MLP. La figure 1 illustre les six filtres du cours sur une image en niveaux de gris : K1 lisse (moyenneur), K2 accentue les contrastes (netteté et lissage), K3/K4 détectent les bords horizontaux et verticaux, K5 approxime l'opérateur de Sobel, K6 capte les transitions diagonales.

FIGURE 1 – Effet des 6 filtres 3×3 sur une image en niveaux de gris.

Résultats CNN et overfitting contrôlé

Le CNN (4 blocs Conv+ReLU+MaxPool, Dropout($p = 0,3$), $\approx 152\,800$ paramètres) atteint **80,83% en test pour 83,41% en train**. L'écart de 2,58 points traduit un overfitting modéré, maîtrisé par l'augmentation de données (flip, crop, luminosité) et le Dropout. **Gain CNN vs meilleur MLP : +30,9 points**. Ce gain provient du partage de poids et de l'invariance de translation, pas du nombre de paramètres.

3 CBIS-DDSM : détection de cancers du sein

Changement de paradigme

1 318 images d'entraînement (681 bénins, 637 malins) et 378 de test. Le critère n'est plus l'accuracy : un faux négatif (cancer non détecté) peut être fatal, tandis qu'une biopsie inutile (faux positif) est gênante mais réversible. On définit :

$$\text{Sensibilité} = \frac{TP}{TP + FN}, \quad \text{Spécificité} = \frac{TN}{TN + FP}$$

et on impose la contrainte clinique Sensibilité $\geq 80\%$. La distribution quasi-équilibrée (48,3% malins) est gérée par des poids $w_c = N/(2n_c)$ intégrés dans l'entropie croisée

Résultats

TABLE 3 – CBIS-DDSM (224×224 px, gris) — résultats aux deux seuils.

Modèle	Seuil par défaut 0,50				Seuil calibré ($\geq 80\%$ sensib.)			
	Acc.	Sensib.	FN	FP	Seuil	Sensib.	Spécif.	FN
MLP [2048, 1024, 512, 256] relu	57,7%	54,4%	67	93	0,38	83,0%	36,8%	25
CNN from scratch	61,9%	39,5%	89	55	0,34	83,7%	26,8%	24
ResNet18 transfer	65,9%	72,8%	40	89	0,42	81,6%	52,4%	27

Analyse de la calibration. À seuil 0,50, le CNN scratch ne détecte que 39,5% des cancers (89 manqués sur 147) : cliniquement inutilisable. En abaissant le seuil à 0,34, la sensibilité monte à 83,7% mais la spécificité tombe à 26,8% : 73% des biopsies prescrites seraient inutiles. ResNet18 offre le meilleur compromis après calibration (seuil = 0,42) : 81,6% de sensibilité avec 52,4% de spécificité — 110 biopsies inutiles mais seulement 27 cancers manqués sur 147. La figure 2 visualise ce transfert avant/après calibration.




FIGURE 2 – ResNet18 — matrices de confusion avant (sensib. 72,8%, FN= 40) et après calibration du seuil à 0,42 (sensib. 81,6%, FN= 27). La calibration réduit les FN de 40 à 27 au prix de +21 FP.

4 Étude d’ablation — régularisation sur CBIS-DDSM

Protocole

7 configurations du même CNN sont testées sous deux conditions de batch : batch physique= 8 avec accumulation×4 (batch effectif= 32) et batch physique= 32 sans accumulation (batch effectif= 32 dans les deux cas). La colonne sensib. expose ce que l’accuracy seule masque.

TABLE 4 – Ablation CBIS-DDSM 128×128 — comparaison batch= 8 vs batch= 32. L_0 = perte à l’époque 1. Grisé = comportement trivial détecté.

Configuration	Batch physique = 8			Batch physique = 32		
	Acc.	Sensib.	L_0	Acc.	Sensib.	L_0
1. Baseline (aucune régul.)	56,1%	66,0%	0,90	52,4%	85,0%	0,95
2. +BatchNorm	61,4%	57,1%	25,5	56,6%	15,6%	26,5
3. +Dropout seul	56,6%	67,3%	1,70	53,7%	61,9%	1,61
4. +BN+Drop+WD	54,8%	42,9%	67,6	51,6%	78,9%	69,6
5. +BCE (sigmoid)	43,9%	89,1%	70,3	49,2%	76,9%	68,2
6. BN momentum= 0,01	53,7%	17,7%	67,7	61,1%	0,0%	69,6
7. MixUp $\alpha = 0,4$	60,8%	40,8%	68,9	59,3%	8,8%	68,6

Analyse des résultats

(1) **La baseline gagne en comportement utile.** Avec 1187 images et 25 époques, le réseau n’a pas le temps de sur-apprendre. Ajouter de la régularisation ralentit la convergence sans overfitting à corriger. La sensibilité de la

baseline (66%) est la meilleure des configurations non-dégénérées.

(2, 4, 6) Instabilité BatchNorm — cause identifiée. BatchNorm normalise par $\hat{x}_i = (x_i - \mu_B) / \sqrt{\sigma_B^2 + \varepsilon}$. Avec un batch physique de 8, μ_B et σ_B^2 sont très bruités : la perte initiale atteint $\times 25$ (config. 2) et $\times 75$ (config. 6).

Point critique : passer à batch= 32 ne résout pas le problème, la perte initiale de la config. 2 reste ≈ 26 dans les deux conditions. L’hypothèse “batch trop petit” est **infirmée expérimentalement** ; la contrainte fondamentale est le volume de données (1 187 images) qui rend les statistiques de BN instables quelle que soit la taille du batch.

(5, 6) Dégénérescence vers prédicteur trivial. La config. 5 (BCE) atteint 43,9% d’accuracy en prédisant massivement “Malin” (sensibilité 89,1%, spécificité 15,2%) : son accuracy correspond presque exactement à la proportion de malins dans le test ($147/378 = 38,9\%$). La config. 6 batch= 32 prédit systématiquement “Bénin” (sensibilité 0%, spécificité 100%, accuracy $61,1\% \approx 231/378$). Ces deux cas illustrent qu’une accuracy nominalement acceptable peut masquer un classifieur cliniquement inutile.

5 Conclusion

TABLE 5 – Synthèse des trois parties.

Dataset	Contrainte principale	Solution clé	Meilleur modèle	Acc.
MNIST	Dataset simple	MLP H=2 sigmoid	MLP [128, 64] sigmoid	96,67%
CIFAR-10	Invariance spatiale	Convolutions	CNN 4 blocs	80,83%
CBIS-DDSM	Petit dataset, FN	Transfer+calibration	ResNet18	65,87%

La réponse à la question transversale est différente à chaque étape. Sur **MNIST**, ni l’architecture ni les données ne limitent réellement : le dataset lui-même est le plafond (233 exemples intrinsèquement ambigus). Sur **CIFAR-10**, l’architecture MLP est le facteur limitant — les convolutions le dépassent de +30,9 points en exploitant l’invariance de translation, indépendamment du nombre de paramètres. Sur **CBIS-DDSM**, les données dominent : trois séries d’ablation sous conditions différentes (batch= 8, batch= 32, résolution 224×224) confirment qu’aucune technique de régularisation ne compense 1 318 images d’entraînement. La solution théorique est GroupNorm (statistiques indépendantes du batch) ou un dataset significativement plus large — la marge vers les 85–88% de la littérature est principalement une contrainte de volume de données, pas d’architecture.

Annexes — Figures




FIGURE 3 – Convergence de la log-loss sur l'ensemble d'entraînement MNIST (linéaire, MLP H=1 [256], MLP H=2 [256, 128]).




FIGURE 4 – Précision test selon la taille des couches cachées sur MNIST. H=1 : [64, 128, 256, 512] — H=2 : [128-64, 256-128, 512-256]. Le rendement marginal s'effondre au-delà de $p_1 = 128$.



FIGURE 5 – Projection ACP 2D de MNIST (2000 exemples test, colorés par classe). Les classes 0 et 1 sont linéairement séparables; les paires (3,8) et (4,9) se chevauchent — plancher des 278 erreurs communes aux trois modèles.




FIGURE 6 – Exemples mal classés simultanément par les trois modèles (278 au total). Formes genuinely ambiguës — pas une limitation du modèle.




FIGURE 7 – Grille précision test (%) sur MNIST : 4 activations $\times$ 5 architectures. Tanh domine (max 98,01%). Heaviside s’effondre au-delà de $H=1$ (gradient nul).




FIGURE 8 – CIFAR-10 — progression des modèles. Gain CNN vs meilleur MLP : +30,9 pp. Références scientifiques : Conv. Deep Belief (78,9%), Maxout (90,6%), ViT (99,5%).



FIGURE 9 – Projection ACP 2D de CIFAR-10 (niveaux de gris). Chevauchement généralisé entre toutes les classes : les features brutes (1 024 scalaires) ne séparent pas les objets naturels sans exploitation de la structure spatiale.




FIGURE 10 – Grille précision test (%) sur CIFAR-10 couleur : 4 activations $\times$ 5 architectures. ReLU gagne (max 48,90% avec $3 \times [256, 128, 64]$). Heaviside échoue systématiquement.




FIGURE 11 – MLP — matrices de confusion avant (sensib. 54,4%, FN= 67) et après calibration à 0,38 (sensib. 83,0%, FN= 25).






FIGURE 12 – Courbes ROC des 3 modèles sur CBIS-DDSM. ResNet18 présente la meilleure AUC, cohérent avec son avantage en sensibilité/spécificité après calibration.



(a) Batch physique = 8



(b) Batch physique = 32

FIGURE 13 – convergence des 7 configurations . Les configs 2, 4, 5, 6 montrent des pertes initiales $\times 25$ à $\times 75$ dans les deux conditions de batch : l'instabilité BN est indépendante du batch, confirmant que la contrainte est le volume de données.