

De la classification des chiffres manuscrits à la détection de cancers du sein

N. Mekideche A. Lauener M. Ouadihi M. Pierson

Juin 2026

Ce rapport analyse trois problèmes de classification d’images de complexité croissante : MNIST (chiffres manuscrits, 10 classes, 60 000 images), CIFAR-10 (objets naturels, 10 classes, 50 000 images) et CBIS-DDSM (mammographies médicales, binaire, 1 696 images). La question fil-rouge est : dans quelle mesure les architectures classiques — linéaire, MLP, CNN — restent-elles applicables lorsque la complexité structurelle des données croît et que les enjeux passent de la reconnaissance académique à la détection clinique ?

1 MNIST : classification de chiffres manuscrits

Données et protocole. Chaque image est aplatie en $\vec{x} \in \mathbb{R}^{784}$, normalisée dans $[0, 1]$. Trois modèles sont entraînés 100 itérations, lr=0,1, batch=256, entropie croisée.

TABLE 1 – MNIST — comparaison des trois modèles (100 iter., lr = 0,1, batch = 256).

Modèle	Params	Err. Train	Err. Test	Acc. Test
Linéaire	7 850	6,95 %	7,55 %	92,45 %
MLP H=1 [64, sigmoid]	50 890	2,84 %	3,57 %	96,43 %
MLP H=2 [64+32, sigmoid]	52 650	2,29 %	3,21 %	96,79 %

Analyse du gap train/test. L’écart entre erreur train et test reste inférieur à 1 pp sur les trois modèles, signe d’une bonne généralisation sans sur-apprentissage. Passer de 7 850 à 52 650 paramètres ($\times 6,7$) ne réduit l’erreur test que de 4,3 pp : le rendement marginal des paramètres supplémentaires diminue rapidement dès que la capacité du modèle dépasse la complexité intrinsèque des données.

Analyse des erreurs partagées. 233 exemples sont mal classés simultanément par les trois modèles. Ces erreurs se concentrent sur les paires (3, 8), (4, 9), (5, 6), confirmée par l’ACP en annexe 1 : les classes 0 et 1 sont nettement séparées dans $\mathbb{R}^{784}$, tandis que 3/8 et 4/9 se chevauchent. Ce plancher d’erreur résiduel est *intrinsèque aux données* — des chiffres genuinement ambigus —, pas une limitation du modèle.

Grille activation $\times$ architecture (tableau 3 en annexe). Tanh domine sigmoid sur toutes les architectures (meilleur : 98,02 % avec tanh $3 \times [256, 128, 64]$), grâce à sa symétrie centrée en 0 qui améliore le conditionnement du gradient. Heaviside illustre rigoureusement le théorème de rétro-propagation : la dérivée étant nulle presque partout ($\mathbf{1}'_{z>0} = 0$ p.p.), le gradient ne traverse pas les couches cachées, et les performances s’effondrent avec la profondeur (84,0 % à H=1, 29,3 % à H=3).

Pourquoi MNIST reste simple. Fond blanc uniforme, chiffres centrés et bonne invariance intra-classe : un modèle linéaire apprend des gabarits efficaces par classe. Ces propriétés disparaissent complètement sur CIFAR-10.

2 CIFAR-10 : classification d’objets naturels

Limite structurelle du MLP. CIFAR-10 présente fonds complexes, translations et occlusions fréquentes. Un MLP appliqué en entrée 3 072 (couleur) ou 1 024 (gris) plafonne rapidement : chaque pixel possède un poids distinct, sans invariance de translation. Un avion en haut à gauche et le même avion en bas à droite activent des poids totalement différents.

TABLE 2 – CIFAR-10 — progression des modèles (50 iter., lr=0,1 pour MLP ; Adam lr=10⁻³ pour CNN).

Modèle	Données	Acc. Test	Err. Test
Linéaire	Gris (1 024)	28,20 %	71,80 %
MLP H=1 [128, sigmoid]	Gris (1 024)	34,24 %	65,76 %
Linéaire	Couleur (3 072)	39,96 %	60,04 %
MLP H=1 [128, sigmoid]	Couleur (3 072)	43,27 %	56,73 %
MLP (meilleur grille) relu	Couleur (3 072)	51,43 %	48,57 %
CNN PyTorch (4 blocs conv.)	Couleur	80,83 %	19,17 %

Observation sur la couleur. Le MLP sigmoid gris culmine à 34,24 % ; avec 3× plus de features couleur, le gain est seulement +9 pp (43,27 %). La couleur brute non structurée nourrit faiblement un MLP de capacité 128 neurones. Avec relu et une architecture plus large (3×[256, 128, 64]), la couleur permet d’atteindre 51,43 % : l’activation non-saturante exploite mieux l’information chromatique que sigmoid dont le gradient s’atténue hors de $[-2, 2]$.

L’opération de convolution. La convolution répond au problème d’invariance spatiale en appliquant le même filtre $K \in \mathbb{R}^{k \times k}$ en toute position :

$$(X * K)[i, j] = \sum_{u=0}^{k-1} \sum_{v=0}^{k-1} X[i+u, j+v] \cdot K[u, v]$$

Partage de poids : un filtre 3×3 (9 paramètres) détecte la même structure locale partout dans l’image, contre 9 paramètres *distincts* par position pour un MLP, soit 32×32×9 = 9 216 poids pour une seule map de features. C’est ce mécanisme — et non l’architecture PyTorch — qui explique le gain de +52,6 pp sur le linéaire gris.

Résultats CNN et overfitting contrôlé. Le CNN (4 blocs conv.+ReLU+MaxPool, Dropout($p = 0,3$), ~152 800 paramètres) atteint 80,83 % test pour 83,41 % train. L’écart de 2,6 pp traduit un overfitting modéré, maîtrisé par l’augmentation de données (flip, crop, luminosité) et le Dropout. À titre de comparaison, les Convolutional Deep Belief Networks (2010) atteignaient 78,9 % ; notre CNN les dépasse légèrement. La marge restante vers Maxout (90,6 %) et ViT (99,5 %) s’explique par la profondeur, le mécanisme d’attention, et la masse de données supplémentaires.

3 CBIS-DDSM : détection de cancers du sein

Changement de paradigme. 1 318 images d’entraînement (681 bénins, 637 malins) et 378 de test. Le critère d’évaluation n’est plus l’accuracy : un faux négatif (cancer non détecté) peut être fatal, tandis qu’une biopsie inutile (faux positif) est gênante mais réversible. On définit donc Sensibilité = $TP/(TP + FN)$ et l’on impose Sensibilité $\geq 80\%$.

TABLE 3 – CBIS-DDSM (224×224 px, gris) — résultats aux deux seuils de décision.

Modèle	Seuil par défaut 0,50			Seuil calibré ($\geq 80\%$ sensib.)		
	Acc.	Sensib.	FN	Seuil	Sensib.	Spécif.
MLP [2048,1024,512,256] relu	60,6 %	57,1 %	63	0,36	84,4 %	29,9 %
CNN from scratch	61,9 %	39,5 %	89	0,34	83,7 %	26,8 %
ResNet18 transfer	65,9 %	72,8 %	40	0,42	81,6 %	52,4 %

Analyse de la calibration du seuil. À seuil 0,5, le CNN scratch ne détecte que 39,5 % des cancers (89 manqués sur 147) : cliniquement inutilisable. En abaissant le seuil à 0,34, la sensibilité monte à 83,7 % mais la spécificité tombe à 26,8 % : 73 % des biopsies prescrites seraient inutiles. ResNet18 offre le meilleur compromis après calibration (seuil = 0,42) : 81,6 % de sensibilité avec 52,4 % de spécificité — 110 biopsies inutiles mais seulement 27 cancers manqués sur 147. Ce résultat montre que le classifieur a appris un signal discriminant réel ; le seuil par défaut 0,5 était simplement le mauvais point d’opération.

Transfer learning et contrainte de données. ResNet18 pré-entraîné sur ImageNet (1,2M images RGB) est adapté en gelant `layer1/layer2` (features de bas niveau universelles : bords, textures, démontrées par Zeiler et Fergus, 2014) et en fine-tunant `layer3/layer4/fc`. Le gain de +4 pp sur le CNN scratch (65,9 % vs 61,9 %) reste modeste au regard des 85–88 % rapportés dans la littérature sur ResNet-50 avec des datasets $\geq 5\,000$ images. La cause principale est la taille du corpus : 1 318 images d’entraînement sont insuffisantes pour spécialiser les représentations de haut niveau à la texture subtile des masses mammaires.

4 Étude d'ablation — régularisation sur CBIS-DDSM

Protocole. 7 configurations du même CNN (128×128, batch physique = 8, accumulation ×4, 25 époques) activent chacune une technique supplémentaire. L'initialisation de Kaiming ($\sigma = \sqrt{2/\text{fan_out}}$) et l'augmentation médicale sont communes à toutes. La colonne *Sensib.* expose ce que l'accuracy seule masque.

TABLE 4 – Ablation (CBIS-DDSM 128×128). Les configs grisées convergent vers un classifieur trivial malgré une accuracy nominale acceptable.

#	Configuration	BN	Acc.	Sensib.	Comportement
1	Baseline (aucune régul.)	—	57,9 %	75,5 %	Équilibré (référence)
2	+ BatchNorm	✓	59,5 %	52,4 %	BN instable, $\mathcal{L}_0 \approx 25$
3	+ Dropout seul	—	41,0 %	99,3 %	<i>Prédit Malin systématiquement</i>
4	+ BN + Dropout + WD	✓	59,5 %	33,3 %	Bug $\text{WD} \rightarrow \gamma \rightarrow 0$, $\mathcal{L}_0 \approx 73$
5	+ BCE (sigmoid, 1 sortie)	✓	61,1 %	10,2 %	<i>Prédit Bénin systématiquement</i>
6	BN momentum = 0,01	✓	60,3 %	14,3 %	Instabilité persistante, $\mathcal{L}_0 \approx 75$
7	BN $m = 0,01$ + MixUp $\alpha = 0,4$	✓	51,6 %	40,1 %	Plus équilibré, convergence lente

(1) La baseline gagne en comportement utile. Le réseau n'a pas le temps de sur-apprendre avec 1 187 images en 25 époques. Ajouter de la régularisation ralentit la convergence sans overfitting à corriger. Avec la sensibilité comme critère clinique, la baseline est la seule configuration vraiment utilisable (75,5 %).

(2–3) Dégénérescences et accuracy trompeuse. La config 3 (Dropout seul) atteint 99,3 % de sensibilité avec 3,9 % de spécificité : le modèle prédit "Malin" systématiquement. Son accuracy de 41,0 % correspond presque exactement à la proportion de malins dans le test ($147/378 = 38,9\%$). La config 5 (BCE) atteint 61,1 % d'accuracy — le meilleur score brut de l'ablation — mais avec une sensibilité de 10,2 % : 132 cancers manqués sur 147. Son accuracy correspond à la proportion de bénins dans le test ($231/378 = 61,1\%$). Ces deux cas illustrent qu'optimiser l'accuracy sur un problème médical binaire peut converger vers un prédicteur trivial parfaitement inutile cliniquement.

(2, 4, 6) Instabilité BatchNorm — batch physique insuffisant. BatchNorm normalise par les statistiques du mini-batch : $\hat{x}_i = (x_i - \mu_B)/\sqrt{\sigma_B^2 + \varepsilon}$. Avec un batch physique de 8, les estimées μ_B et σ_B^2 sont très bruitées. La perte initiale atteint ×25 (config 2), ×73 (config 4) et ×75 (config 6) par rapport à la baseline. *Point critique* : l'accumulation de gradients (batch effectif = 32) ne résout **pas** ce problème — BN calcule ses statistiques sur le batch *physique*, pas sur le batch effectif. Un momentum réduit ($m = 0,01$) n'y change rien.

(4) Bug identifié : weight decay appliqué aux paramètres BatchNorm. `Adam(model.parameters(), weight_decay= $\lambda$ )` applique la pénalité L_2 aux paramètres γ (scale) de chaque couche BN. Or γ sous régularisation L_2 converge vers 0, supprimant progressivement la normalisation et provoquant la perte explosive observée. Correction : deux groupes de paramètres distincts (BN exclus du weight decay).

5 Conclusion

- L'architecture doit correspondre à la structure des données.** Les convolutions gagnent +52,6 pp sur le linéaire CIFAR-10 en exploitant l'invariance de translation, indépendamment du nombre de paramètres.
- L'accuracy est un mauvais critère en domaine médical.** La config 5 de l'ablation dépasse la baseline de +3,2 pp en accuracy en prédisant systématiquement "Bénin" — manquant 89 % des cancers. Sensibilité, spécificité et calibration du seuil sont indispensables.
- La régularisation n'aide qu'en présence d'overfitting.** Sur 1 187 exemples en 25 époques, Dropout et BatchNorm nuisent à la convergence. La condition nécessaire est que le réseau ait assez de données et d'itérations pour commencer à sur-apprendre, ce qui n'est pas le cas ici.
- BatchNorm requiert des batches physiques ≥ 32 .** Gradient accumulation $\neq$ grande batch pour BN. Alternative : GroupNorm ou InstanceNorm, dont les statistiques sont indépendantes de la taille du batch.
- Le transfer learning compense partiellement le manque de données.** ResNet18 apporte +4 pp sur le CNN scratch. La marge vers les 85–88 % de la littérature est principalement une contrainte de volume de données, pas d'architecture.

Annexes




FIGURE 1 – ACP 2D de MNIST. Les classes 0 et 1 sont linéairement séparables ; le chevauchement des paires (3,8) et (4,9) explique le plancher des 233 erreurs communes aux trois modèles.




FIGURE 2 – Exemples mal classés par les trois modèles simultanément. Formes genuinely ambiguës — pas une limitation du modèle.




FIGURE 3 – Grille precision test (%) sur MNIST : 4 activations $\times$ 5 architectures. Tanh domine (max 98,02 %). Heaviside s'effondre au-delà de H=1.




FIGURE 4 — Effet des 6 filtres 3×3 sur une image. De gauche à droite : original, K1 flou, K2 netteté, K3 bords horizontaux, K4 bords verticaux, K5 Sobel, K6 diagonal.




FIGURE 5 — Grille precision test (%) sur CIFAR-10 couleur. ReLU gagne (51,43 % avec $3 \times [256, 128, 64]$), Heaviside échoue.




FIGURE 6 — ACP 2D de CIFAR-10. Chevauchement généralisé entre toutes les classes : les features brutes (1024 ou 3072 scalaires) ne séparent pas les objets naturels sans exploitation de la structure spatiale.






FIGURE 7 – Convergence train/validation du CNN sur CIFAR-10. L'écart 83,41 % / 80,83 % reste stable : le Dropout ($p = 0,3$) maintient l'overfitting à 2,6 pp.



(a) Seuil 0,50 — sensibilité 72,8 %, FN = 40

(b) Seuil calibré 0,42 — sensibilité 81,6 %, FN = 27

FIGURE 8 – ResNet18 — matrices de confusion avant et après calibration du seuil. La calibration réduit les FN de 40 à 27 au prix de +21 FP.



(a) Perte entraînement

(b) Perte validation

FIGURE 9 – Ablation — convergence des 7 configurations. Les configs 2, 4, 5, 6 montrent des pertes initiales $\times 25$ à $\times 75$: BN instable sur batch physique = 8. La config 1 (baseline) est la seule avec une convergence stable.

Références citées.

- Lee et al. (2009). *Convolutional Deep Belief Networks for Scalable Unsupervised Learning of Hierarchical Representations*. ICML 2009 — 78,9 % CIFAR-10.
- Goodfellow et al. (2013). *Maxout Networks*. ICML 2013 — 90,6 % CIFAR-10.
- Dosovitskiy et al. (2021). *An Image is Worth 16x16 Words : Transformers for Image Recognition at Scale*. ICLR 2021 — 99,5 % CIFAR-10.

— Zeiler & Fergus (2014). *Visualizing and Understanding Convolutional Networks*. ECCV 2014 — universalité des features de bas niveau.